Betriebssysteme (BS)

Interprozesskommunikation

Olaf Spinczyk
Arbeitsgruppe Eingebettete Systemsoftware

Lehrstuhl für Informatik 12
TU Dortmund

Olaf.Spinczyk@tu-dortmund.de
http://ess.cs.uni-dortmund.de/~os/

Inhalt

- Wiederholung
- Grundlagen der Interprozesskommunikation
- Lokale Interprozesskommunikation unter UNIX
  - Signale
  - *Pipes*
  - *Message Queues*
- Rechnerübergreifende Interprozesskommunikation
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- Zusammenfassung

Inhalt

- **Wiederholung**
- Grundlagen der Interprozesskommunikation
- Lokale Interprozesskommunikation unter UNIX
  - Signale
  - *Pipes*
  - *Message Queues*
- Rechnerübergreifende Interprozesskommunikation
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- Zusammenfassung

Wiederholung

- Prozesse können miteinander interagieren
  - Aufeinander warten (**Synchronisation**)
  - Daten austauschen (**Kommunikation**)
- Wartemechanismen ...
  - sind notwendig für kontrollierte Kommunikation
  - können zu Verklemmungen führen
- Datenaustausch wurde bisher nur am Rande betrachtet
  - UNIX System V Shared Memory
  - Leicht- und federgewichtige Prozesse im selben Adressraum

Inhalt

- Wiederholung
- **Grundlagen der Interprozesskommunikation**
- Lokale Interprozesskommunikation unter UNIX
  - Signale
  - *Pipes*
  - *Message Queues*
- Rechnerübergreifende Interprozesskommunikation
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- Zusammenfassung

Interprozesskommunikation

Inter-Process-Communication **(IPC)**

- Mehrere Prozesse bearbeiten **eine** Aufgabe
  - gleichzeitiges Nutzung von zur Verfügung stehender Information durch mehrere Prozesse
  - Verkürzung der Bearbeitungszeit durch Parallelisierung
- Kommunikation durch gemeinsamen Speicher
  - Datenaustausch nebenläufiges Schreiben in bzw. Lesen aus einem gemeinsamen Speicher
  - Dabei muss auf Synchronisation geachtet werden
- **Heute: Kommunikation durch Nachrichten**
  - Nachrichten werden zwischen Prozessen ausgetauscht
  - Gemeinsamer Speicher ist nicht erforderlich

Nachrichtenbasierte Kommunikation

- ... basiert auf zwei Primitiven:

```
send (Ziel, Nachricht)
receive (Quelle, Nachricht)
```

(oder ähnlich)

- Unterschiede gibt es in ...
  - Synchronisation
  - Adressierung
  - und diversen anderen Eigenschaften ;-)

Synchronisation

... bei nachrichtenbasierter Kommunikation

- **Synchronisation bei Senden / Empfangen**
  - **Synchroner Nachrichtenaustausch** (auch „***Rendezvous***“)
    - Empfänger blockiert bis die Nachricht eingetroffen ist.
    - Sender blockiert bis die Ankunft der Nachricht bestätigt ist.
  - **Asynchroner Nachrichtenaustausch**
    - Sender gibt die Nachricht dem Betriebssystem und arbeitet weiter
    - Blockierung auf beiden Seiten optional
    - Pufferung immer erforderlich
- Häufig anzutreffen:
  - Asynchroner Nachrichtenaustausch mit potentiell blockierendem Senden und Empfangen

Adressierung

... bei nachrichtenbasierter Kommunikation

- **Direkte Adressierung**
  - Prozess-ID (Signale)
  - Kommunikationsendpunkt eines Prozesses (*Port*, *Socket*)
- **Indirekte Adressierung**
  - Kanäle (*Pipes*)
  - Briefkästen (*Mailboxes*), Nachrichtenpuffer (*Message Queues*)
- Zusätzliche Dimension: **Gruppenadressierung**
  - ***Unicast*** – an genau einen
  - ***Multicast*** – an eine Auswahl
  - ***Broadcast*** – an alle

Diverse andere Eigenschaften

... bei nachrichtenbasierte Kommunikation

- **Nachrichtenformat**
  - Stromorientiert / nachrichtenorientiert
  - Fest Länge / variable Länge
  - Getypt / ungetypt
- **Übertragung**
  - Unidirektional / Bidirektional (halb-duplex, voll-duplex)
  - zuverlässig / unzuverlässig
  - Reihenfolge bleibt erhalten / nicht erhalten

Inhalt

- Wiederholung
- Grundlagen der Interprozesskommunikation
- **Lokale Interprozesskommunikation unter UNIX**
  - Signale
  - *Pipes*
  - *Message Queues*
- Rechnerübergreifende Interprozesskommunikation
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- Zusammenfassung

UNIX Signale

- Signale sind in Software nachgebildete Unterbrechungen
  - ähnlich denen eines Prozessors durch E/A-Geräte
  - minimale Form der Interprozesskommunikation (Übertragung der Signalnummer)
- Sender:
  - Betriebssystem bei bestimmten Ereignissen
  - Prozesse mit Hilfe des Systemaufrufs **kill**
- Empfänger-Prozess führt Signalbehandlung durch
  - Ignorieren
  - Terminierung des Prozesses
  - Aufruf einer Behandlungsfunktion
    - Nach der Behandlung läuft Prozess an unterbrochener Stelle weiter

UNIX Signale: Logische Sicht

- Hollywood-Prinzip: *„Don't call us, we'll call you.“*

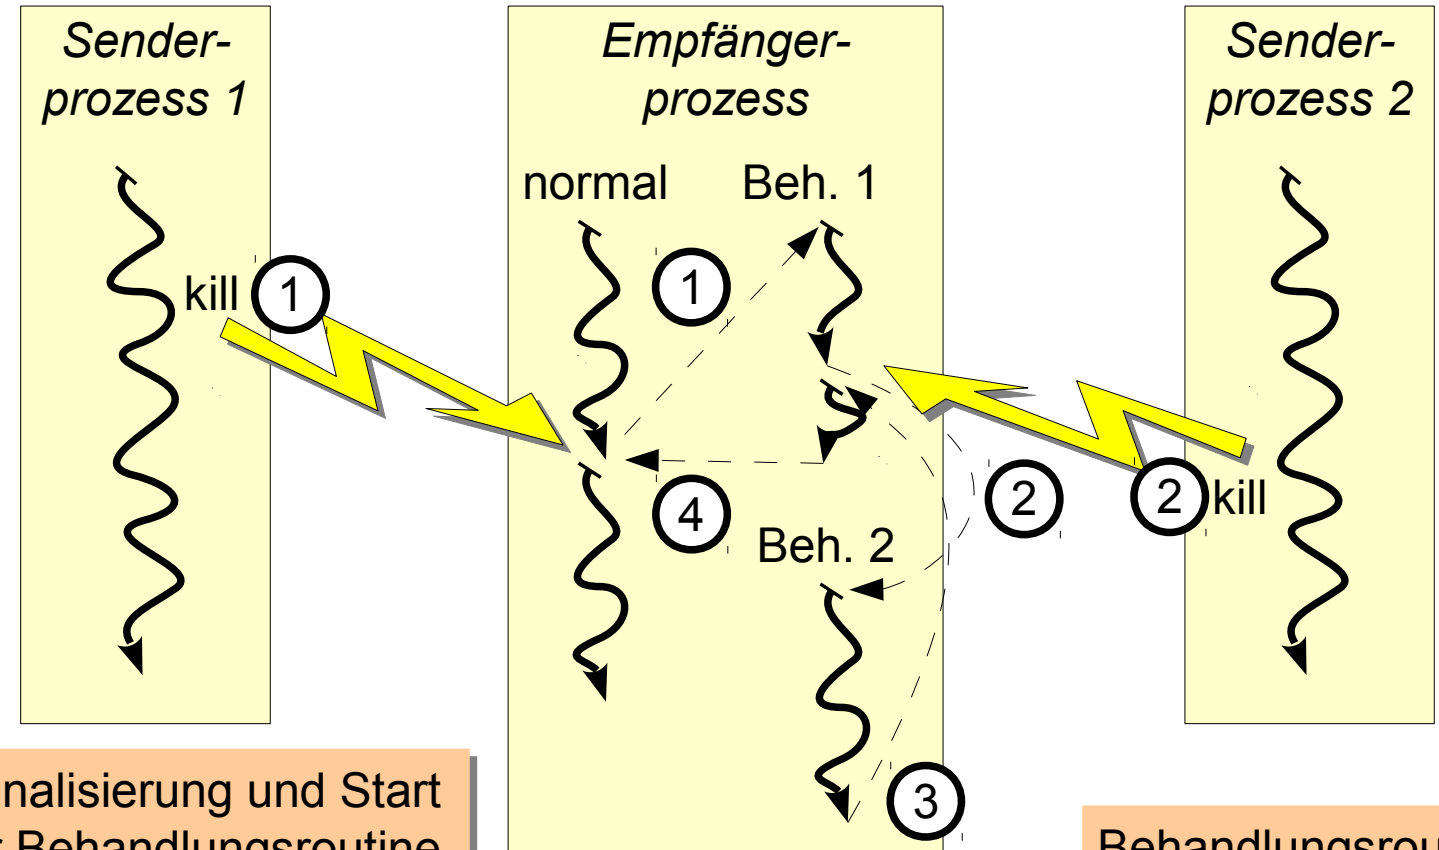

Signalisierung und Start der Behandlungsroutine erfolgen in der logischen Sicht gleichzeitig.

Behandlungsroutinen können auch unterbrochen werden.

UNIX Signale: Technische Sicht

- Die Signalbehandlung erfolgt immer beim Übergang vom *Kernel* in der *User Mode*.
- Was passiert also wirklich, wenn der Zielprozess gerade ...

1. läuft, also **RUNNING** (z.B. *Segmentation Fault*, *Bus Error*)?
   - Unmittelbarer Start der Behandlungsroutine
2. gerade nicht läuft, aber **READY** ist (z.B. **kill** Systemaufruf)?
   - Im Prozesskontrollblock wird das Signal vermerkt.
   - Wenn der Prozess die CPU zugeteilt bekommt, erfolgt die Behandlung
3. auf E/A wartet, also **BLOCKED** ist?
   - Der E/A Systemaufruf (z.B. **read**) wird mit EINTR abgebrochen.
   - Der Prozesszustand wird auf READY gesetzt.
   - Danach wie bei 2.
   - Ggf. wird der unterbrochene Systemaufruf neu ausgeführt (SA_RESTART)

UNIX Signale: Beispiel

- Auszug aus dem Handbuch des ***Apache*** HTTP Servers

Stopping and Restarting Apache

To send a signal to the parent you should issue a command such as:

kill -TERM `cat /usr/local/apache/logs/httpd.pid`

TERM Signal: stop now

Sending the TERM signal to the parent causes it to immediately attempt to kill off all of its children. It may take it several seconds to complete killing off its children. Then the parent itself exits. Any requests in progress are terminated, and no further requests are served.

HUP Signal: restart now

Sending the HUP signal to the parent causes it to kill off its children like in TERM but the parent doesn't exit. It **re-reads its configuration files**, and **re-opens any log files**. Then it spawns a new set of children and continues serving hits.

USR1 Signal: graceful restart

The USR1 signal causes the parent process to advise the children to exit after their current request (or to exit immediately if they're not serving anything). The parent re-reads its configuration files and re-opens its log files. As each child dies off the parent replaces it with a child from the new generation of the configuration, which begins serving new requests immediately.

UNIX *Pipes*

- Kanal zwischen zwei Kommunikationspartnern
  - unidirektional
  - gepuffert (feste Puffergröße)
  - zuverlässig
  - stromorientiert
- Operationen: Schreiben und Lesen
  - Ordnung der Zeichen bleibt erhalten (Zeichenstrom)
  - Blockierung bei voller Pipe (Schreiben) und leerer Pipe (Lesen)

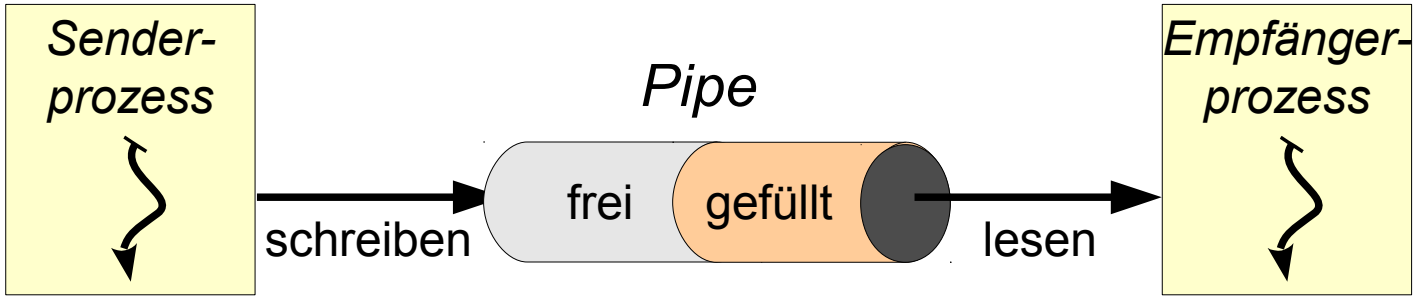

UNIX *Pipes*: Programmierung

- **Unbenannte *Pipes***
  - Erzeugen einer Pipe: `int pipe (int fdes[2])`
  - Nach erfolgreichem Aufruf (Rückgabewert == 0) kann man ...
    - über fdes[0] aus der *Pipe* lesen (Systemaufruf **read**)
    - über fdes[1] in die *Pipe* schreiben (Systemaufruf **write**)
  - Nun muss man nur noch das eine Ende an einen anderen Prozess weitergeben (siehe nächste Folie)
- **Benannte *Pipes***
  - *Pipes* können auch als Spezialdateien ins Dateisystem gelegt werden: `int mkfifo (<Dateiname>, mode_t mode)`
  - Standardfunktionen zum Öffnen, Lesen, Schreiben und Schließen können dann verwendet werden.
    - Normale Dateizugriffsrechte regeln, wer die *Pipe* benutzen darf.

UNIX *Pipes*: Beispiel – *connect*

```
enum { READ=0, WRITE=1 };

int main (int argc, char *argv[]) {
  int res, fd[2];
  if (pipe (fd) == 0) {          /* Pipe erzeugen */
    res = fork ();
    if (res > 0) {               /* Elternprozess */
      close (fd[READ]);                  /* Leseseite schließen */
      dup2 (fd[WRITE], 1);               /* Std-Ausgabe in Pipe */
      close (fd[WRITE]);                 /* Deskriptor freigeben */
      execlp (argv[1], argv[1], NULL); /* Schreiber ausführen */
    }
    else if (res == 0) {         /* Kindprozess */
      close (fd[WRITE]);                 /* Schreibseite schließen */
      dup2 (fd[READ], 0);                /* Std-Eingabe aus Pipe */
      close (fd[READ]);                  /* Deskriptor freigeben */
      execlp (argv[2], argv[2], NULL); /* Leser ausführen */
    }
  }
  ...Fehler behandeln
}
```

UNIX *Pipes*: Beispiel

```
enum { READ=0, WRITE=1 };

int main (int argc, char *argv[]) {
  int res, fd[2];
  if (pipe (fd) == 0) {          /* Pipe e
    res = fork ();
```

„**./connect ls wc**“ entspricht dem Shell Kommando „**ls|wc**“

```
olaf@xantos:~/V_BSRvS1/vorlesung/code> ls
connect  connect.c  execl.c  fork.c  orphan.c  wait.c
olaf@xantos:~/V_BSRvS1/vorlesung/code> ./connect ls wc
       6       6      49
```

```
    else if (res == 0) {         /* Kindprozess */
      close (fd[WRITE]);                 /* Schreibseite schließen */
      dup2 (fd[READ], 0);                /* Std-Eingabe aus Pipe */
      close (fd[READ]);                  /* Deskriptor freigeben */
      execlp (argv[2], argv[2], NULL); /* Leser ausführen */
    }
  }
  ...Fehler behandeln
}
```

UNIX *Message Queues*

- Rechnerlokale Adresse (*Key*) dient zur Identifikation
- Prozesslokale Nummer (MsqID) wird bei allen Operationen benötigt
- Zugriffsrechte wie auf Dateien
- ➔ Wie bei System V Semaphoren & *Shared Memory*

- ungerichtete M:N Kommunikation
- gepuffert
  - einstellbare Größe pro *Queue*
- Nachrichten haben einen Typ (long-Wert)
- Operationen zum Senden und Empfangen einer Nachricht
  - blockierend — nicht-blockierend (aber nicht asynchron)
  - Empfang aller Nachrichten — nur ein bestimmter Typ

UNIX *Message Queues*

- Rechnerlokale Adresse (*Key*) dient zur Identifikation
- R
  C
- Z
- ➔ V
- u
- g
  - •
- N
- C t
  - •

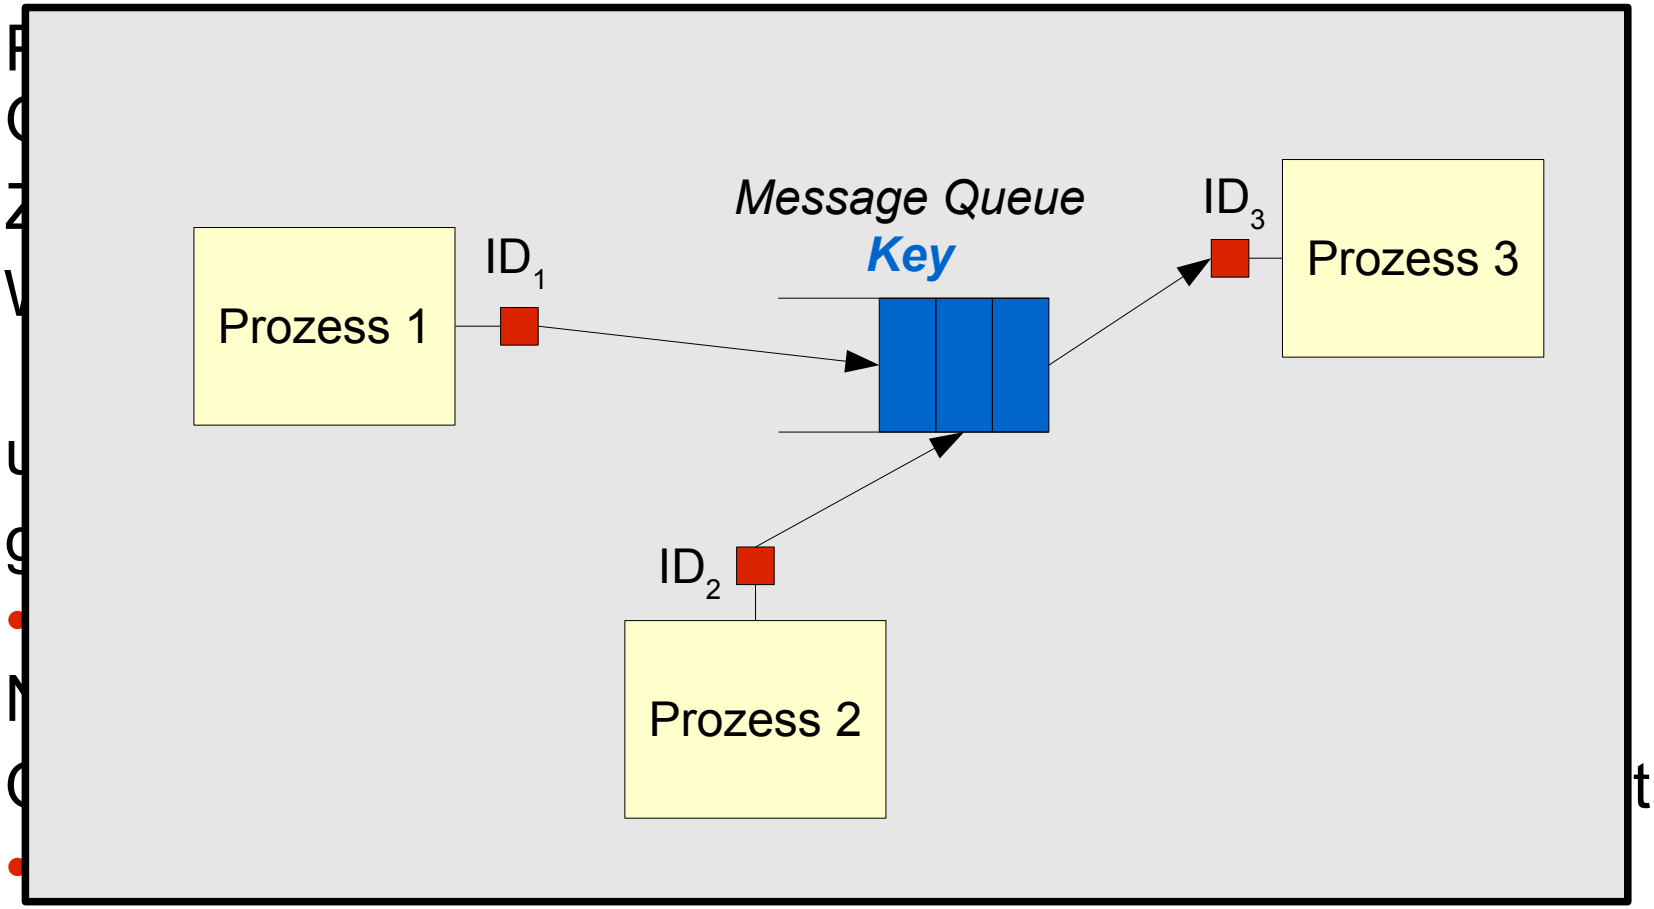

  - alle Nachrichten — nur ein bestimmter Typ

UNIX *Message Queues*: Programmierung

- Erzeugen einer *Message Queue* und holen einer MsqID

```
int msgget (key_t key, int msgflg);
```

  - Alle kommunizierenden Prozesse müssen den *Key* kennen
  - *Keys* sind eindeutig innerhalb eines (Betriebs-)Systems
  - Ist ein *Key* bereits vergeben, kann keine *Message Queue* mit gleichem *Key* erzeugt werden
- Es können *Message Queues* ohne Key erzeugt werden (private Queues, key=IPC_PRIVATE)
  - Nicht-private *Message Queues* sind persistent
  - Sie müssen explizit gelöscht werden (cmd=IPC_RMID):

```
int msgctl (int msqid, int cmd
            struct msqid_ds *buf);
```

UNIX *Message Queues*: Programmierung

- Senden einer Nachricht

```
int msgsnd (int msqid, const void *msgp,
            size_t msgsz, int msgflg);
```

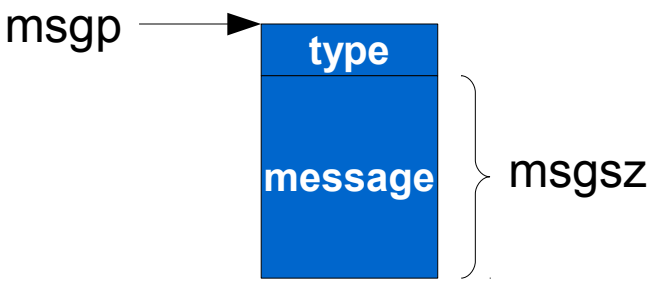

- Empfangen einer Nachricht

```
int msgrcv (int msqid, void *msgp, size_t msgsz,
            long msgtype, int msgflg);
```

  - msgtype=0: erste Nachricht
  - msgtype>0: erste Nachricht mit diesem Typ
  - msgtype<0: Nachricht mit kleinstem Typ <= |msgtype|

UNIX *Message Queue*: Kommandos

- Anzeigen aktiver *Message Queues*

```
ipcs -q
```

- Löschen von *Message Queues*

```
ipcrm -Q <key>
```

UNIX *Message Queues*: Beispiel

[intentionally left blank]

Inhalt

- Wiederholung
- Grundlagen der Interprozesskommunikation
- Lokale Interprozesskommunikation unter UNIX
  - Signale
  - *Pipes*
  - *Message Queues*
- **Rechnerübergreifende Interprozesskommunikation**
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- Zusammenfassung

Sockets

- Allgemeine Kommunikationsendpunkte
  - Bidirektional
  - Gepuffert
- Abstrahiert von Details des Kommunikationssystems
  - Beschrieben durch Domäne (Protokollfamilie), Typ und Protokoll

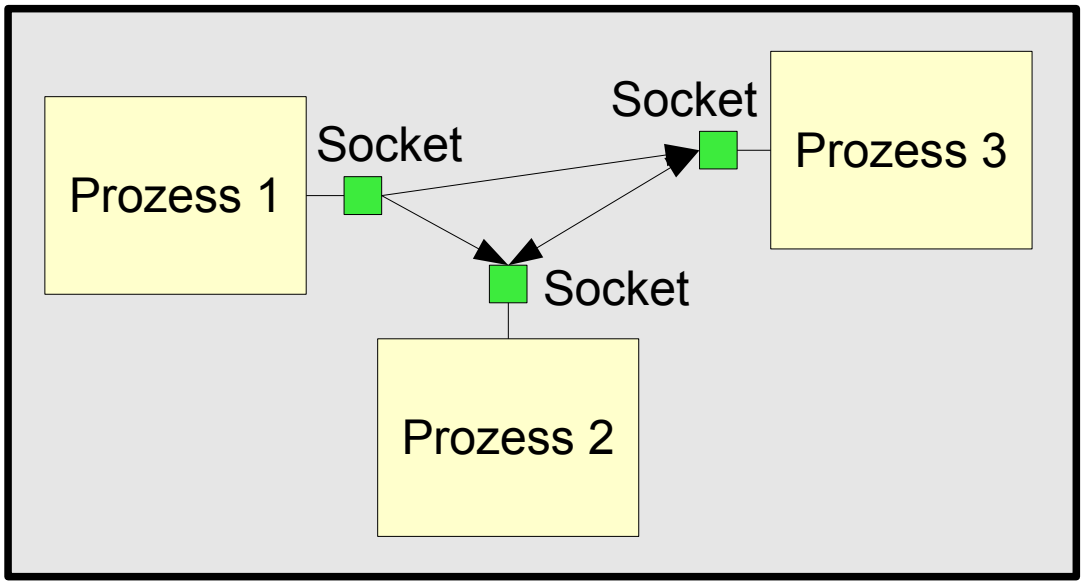

Sockets: Domänen

- UNIX *Domain*
  - UNIX *Domain Sockets* verhalten sich wie bidirektionale *Pipes*.
  - Anlage als Spezialdatei im Dateisystem möglich.
- *Internet Domain*
  - Dienen der rechnerübergreifenden Kommunikation mit Internet Protokollen
- Appletalk *Domain*, DECnet *Domain*, ...

- Domänen bestimmen mögliche Protokolle
  - z.B. *Internet Domain*: TCP/IP oder UDP/IP
- Domänen bestimmen die Adressfamilie
  - z.B. *Internet Domain*: IP-Adresse und *Port*-Nummer

Sockets: Typ und Protokoll

- Die wichtigsten Sockettypen:
  - stromorientiert, verbindungsorientiert und gesichert
  - nachrichtenorientiert und ungesichert
  - nachrichtenorientiert und gesichert
- Protokolle der *Internet Domain*:
  - TCP/IP Protokoll
    - strom- und verbindungsorientiert, gesichert
  - UDP/IP Protokoll
    - nachrichtenorientiert, verbindungslos, ungesichert
    - Nachrichten können verloren oder dupliziert werden
    - Reihenfolge kann durcheinander geraten
    - Paketgrenzen bleiben erhalten (Datagramm-Protokoll)
- → Protokollangabe ist oft redundant

Sockets: Programmierung

- Anlegen von Sockets
  - Generieren eines Sockets mit (Rückgabewert ist ein Filedeskriptor)

```
int socket (int domain, int type, int proto);
```

  - Adresszuteilung
    - Sockets werden ohne Adresse generiert
    - Adressenzuteilung erfolgt durch:

```
int bind (int socket,
          const struct sockaddr *address,
          socklen_t address_len);
```

    - **struct sockaddr_in** (für die Internet Adressfamilie) enthält:

sin_family: AF_INET
sin_port: 16 Bit Portnummer
sin_addr: Struktur mit der IP-Adresse, z.B. 192.168.2.1

Sockets: Programmierung

- ***Datagram Sockets***
  - Kein Verbindungsaufbau notwendig
  - Datagramm senden

```
ssize_t sendto (int socket, const void *message,
                size_t length, int flags,
                const struct sockaddr *dest_addr,
                socklen_t dest_len);
```

  - Datagramm empfangen

```
ssize_t recvfrom (int socket, void *buffer,
                  size_t length, int flags,
                  struct sockaddr *address,
                  socklen_t *address_len);
```

Sockets: Programmierung

- ***Stream Sockets***
  - Verbindungsaufbau notwendig
  - *Client* (Benutzer, Benutzerprogramm) will zu einem Server (Dienstanbieter) eine Kommunikationsverbindung aufbauen
- *Client*: Verbindungsaufbau bei stromorientierten Sockets
  - Verbinden des Sockets mit

```
int connect (int socket,
             const struct sockaddr *address,
             socklen_t address_len);
```

  - Senden und Empfangen mit **write** und **read** (oder **send** und **recv**)
  - Beenden der Verbindung mit **close** (schließt den *Socket*)

Sockets: Programmierung

- *Server*: akzeptiert Anfragen/Aufträge
  - bindet *Socket* an eine Adresse (sonst nicht erreichbar)
  - bereitet *Socket* auf Verbindungsanforderungen vor durch

```
int listen (int s, int queuelen);
```

  - akzeptiert einzelne Verbindungsanforderungen durch

```
int accept (int s, struct sockaddr *addr,
            socklen_t *addrlen);
```

    - gibt einen neuen Socket zurück, der mit dem Client verbunden ist
    - blockiert, falls kein Verbindungswunsch vorhanden
  - liest Daten mit **read** und führt den angebotenen Dienst aus
  - schickt das Ergebnis mit **write** zurück zum Sender
  - schließt den neuen Socket mit **close**

Sockets: Beispiel HTTP Echo

```
#define PORT 6789
#define MAXREQ (4096*1024)

char buffer[MAXREQ], body[MAXREQ], msg[MAXREQ];

void error(const char *msg) { perror(msg); exit(1); }

int main() {
  int sockfd, newsockfd;
  socklen_t clilen;
  struct sockaddr_in serv_addr, cli_addr;
  int n;
  sockfd = socket(PF_INET, SOCK_STREAM, 0);
  if (sockfd < 0) error("ERROR opening socket");
  bzero((char *) &serv_addr, sizeof(serv_addr));
  serv_addr.sin_family = AF_INET;
  serv_addr.sin_addr.s_addr = INADDR_ANY;
  serv_addr.sin_port = htons(PORT);
  if (bind(sockfd, (struct sockaddr *) &serv_addr, sizeof(serv_addr)) < 0)
    error("ERROR on binding");
  listen(sockfd,5);
  ...
```

Hier wird der Socket erstellt und an eine Adresse gebunden.

Sockets: Beispiel HTTP Echo

```
  ...
  while (1) {
    clilen = sizeof(cli_addr);
    newsockfd = accept (sockfd, (struct sockaddr *) &cli_addr, &clilen);
    if (newsockfd < 0) error("ERROR on accept");
    bzero(buffer,sizeof(buffer));
    n = read (newsockfd,buffer,sizeof(buffer)-1);
    if (n < 0) error("ERROR reading from socket");
    snprintf (body, sizeof (body),
              "<html>\n<body>\n"
              "<h1>Hallo Webbrowser</h1>\nDeine Anfrage war ...\n"
              "<pre>%s</pre>\n"
              "</body>\n</html>\n", buffer);
    snprintf (msg, sizeof (msg),
              "HTTP/1.0 200 OK\n"
              "Content-Type: text/html\n"
              "Content-Length: %d\n\n%s", strlen (body), body);
    n = write (newsockfd,msg,strlen(msg));
    if (n < 0) error("ERROR writing to socket");
    close (newsockfd);
  }
}
```

Eine neue Verbindung akzeptieren

HTTP Anfrage einlesen

Antwort generieren und zurückschicken

Verbindung wieder schließen.

Sockets: Beispiel HTTP Echo

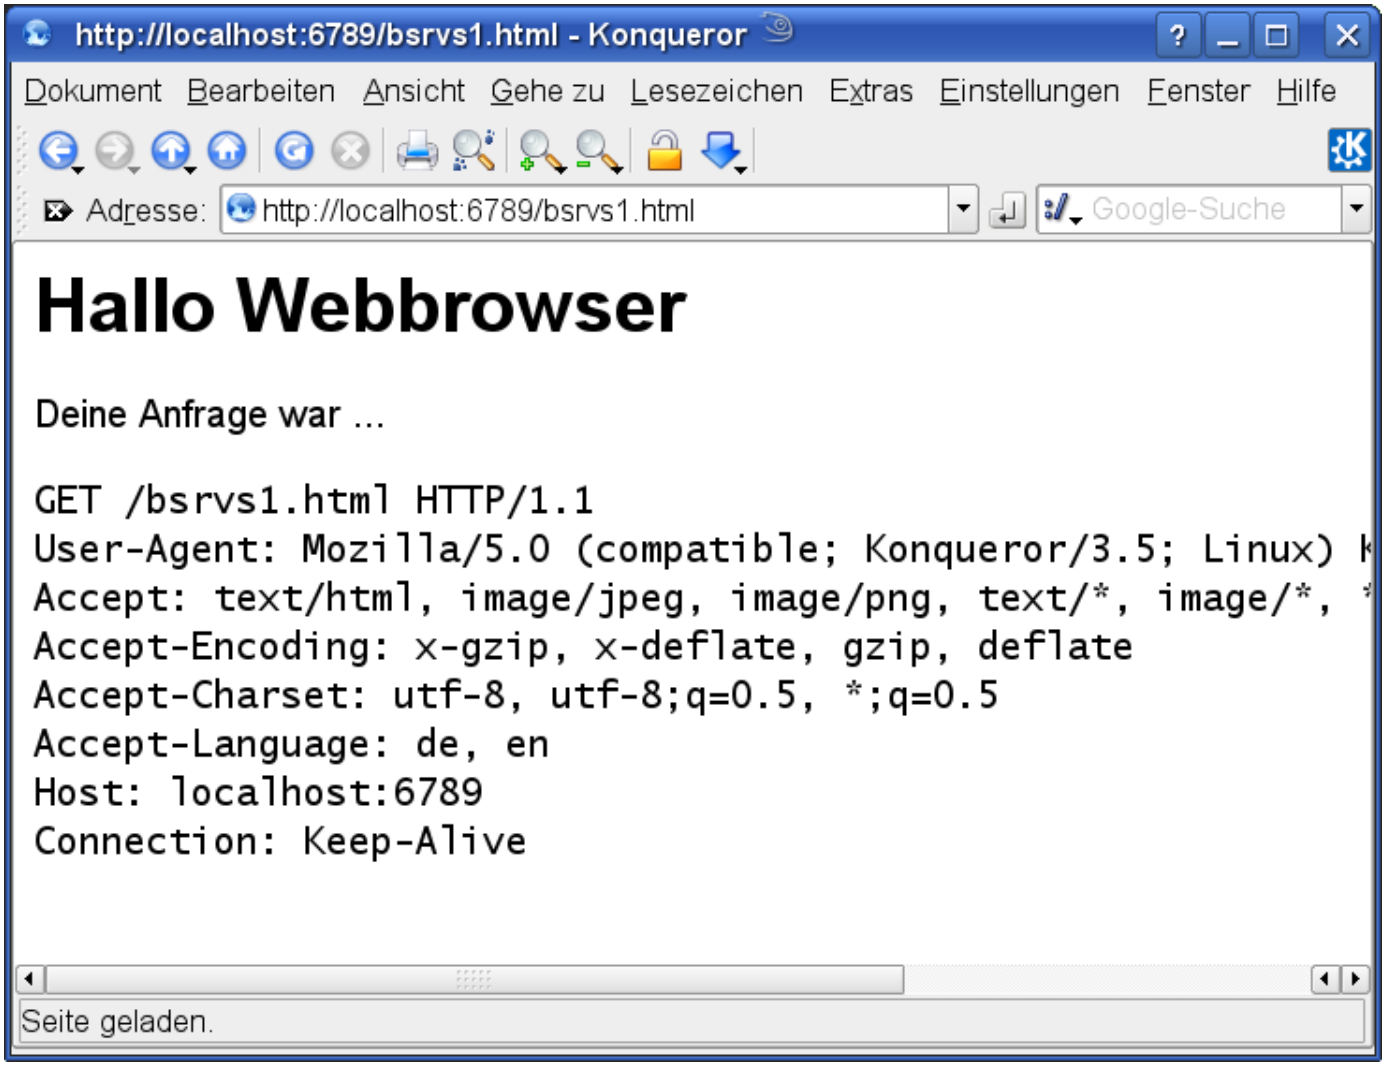

Fernaufruf (RPC)

- Funktionsaufruf über Prozessgrenzen hinweg (***Remote Procedure Call***)
  - hoher Abstraktionsgrad
  - selten wird Fernaufruf direkt vom System angeboten; benötigt Abbildung auf andere Kommunikationsformen z.B. auf Nachrichten
  - Abbildung auf mehrere Nachrichten
    - Auftragsnachricht transportiert Aufrufabsicht und Parameter.
    - Ergebnisnachricht transportiert Ergebnisse des Aufrufs.

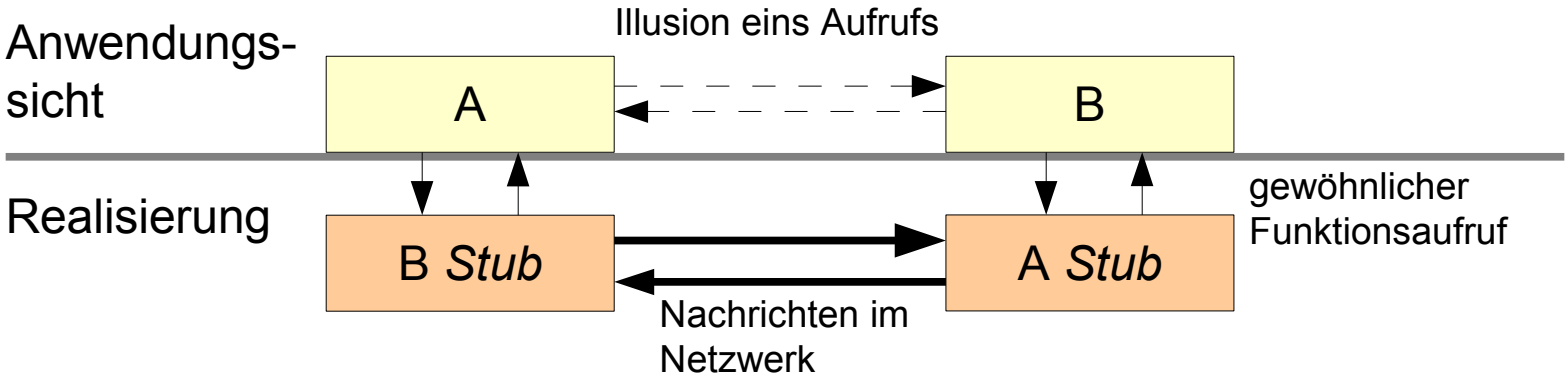

- Beispiele: NFS (ONC RPC), Linux D-BUS

Inhalt

- Wiederholung
- Grundlagen der Interprozesskommunikation
- Lokale Interprozesskommunikation unter UNIX
  - Signale
  - *Pipes*
  - *Message Queues*
- Rechnerübergreifende Interprozesskommunikation
  - *Sockets*
  - Entfernte Prozeduraufrufe (RPCs)
- **Zusammenfassung**

Zusammenfassung

- Es gibt zwei Arten der Interprozesskommunikation
  - nachrichtenbasiert
    - die Daten werden kopiert
    - geht auch über Rechnergrenzen
  - über gemeinsamen Speicher
    - war heute nicht dran
- UNIX Systeme bieten verschiedene Abstraktionen
  - Signale, *Pipes*, *Sockets*, *Message Queues*
  - Insbesondere die *Sockets* werden häufig verwendet.
    - Ihre Schnittstelle wurde standardisiert.
    - Praktisch alle Vielzweckbetriebssysteme implementieren heute *Sockets*.